



Как мы разворачивали своё распределённое \$3 хранилище на базе MinIO

Алексей Плетнёв Базис-Центр zix@bazissoft.ru

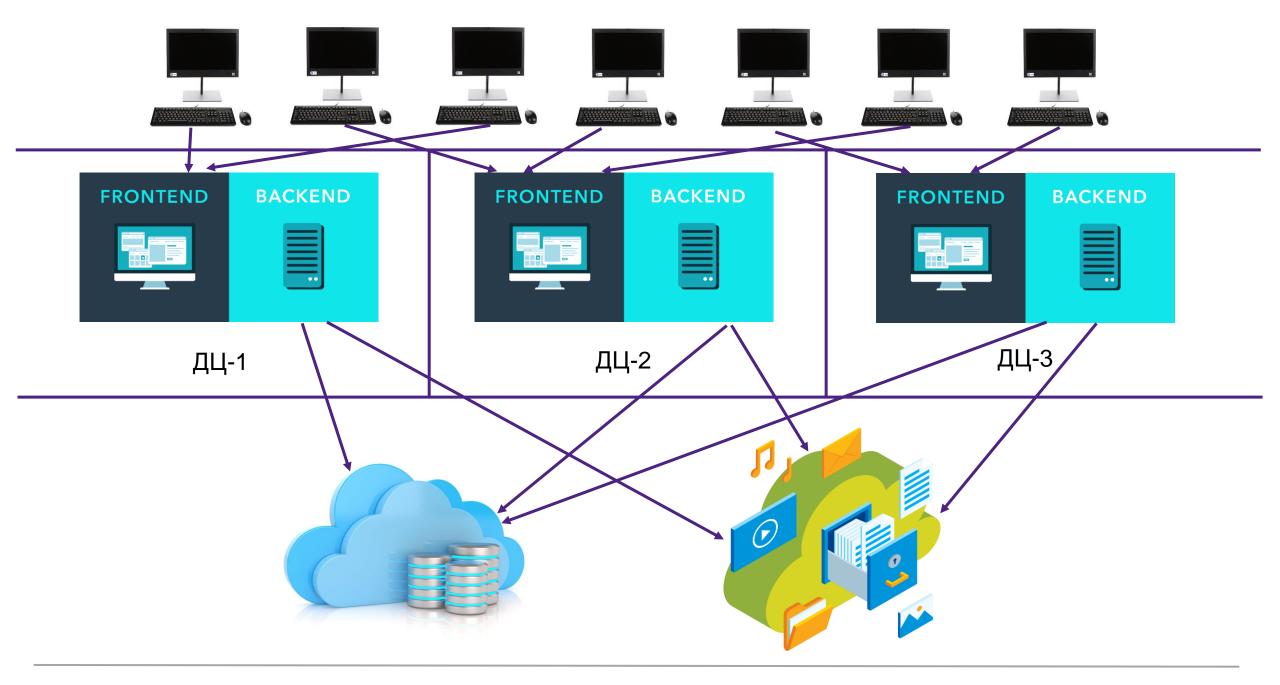
Зачем нам хранилище, почему распределённое и почему S3

Немного о компании

БАЗИС – комплексная система автоматизации проектирования и технологической подготовки производства корпусной мебели.

- 1988 г. первая версия АС БАЗИС для СМ ЭВМ 3 поколения
- 1997 г. первая версия для ОС Windows
- 2005 г. первая версия с трёхмерным математическим ядром
- 2010 г. флагманы российской мебельной промышленности полностью автоматизировали циклы производства с помощью САПР БАЗИС
- 2013 г. полная совместимость программных решений с оборудованием ведущих производителей
- 2016 г. выход на международный рынок

P.S. Команда разработчиков 15 человек



Какие есть варианты

ОБЛАЧНЫЕ









ЛОКАЛЬНЫЕ









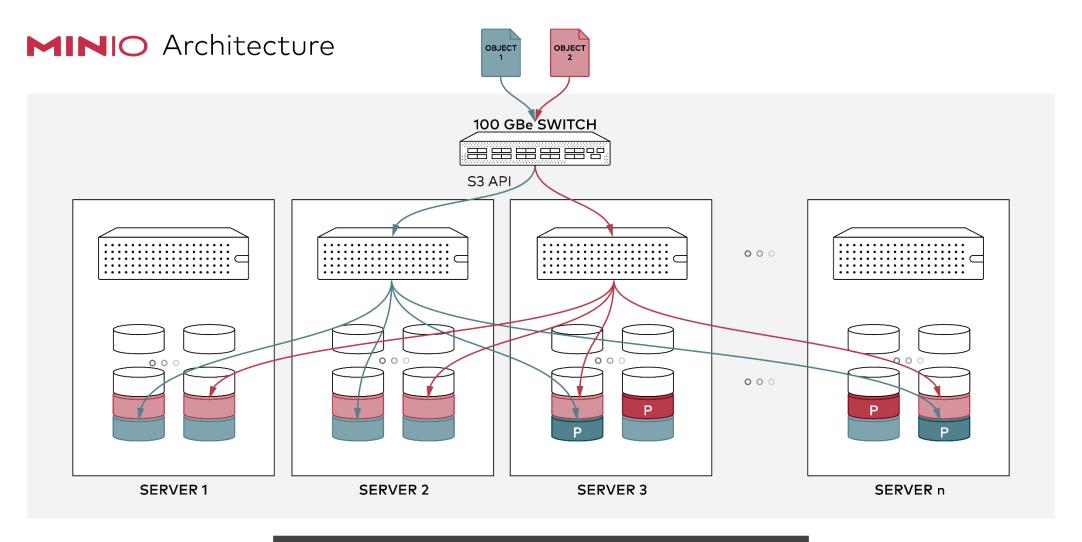
Сравнение стоимости

Сравнение стоимости (с поддержкой)

Почему MinIO

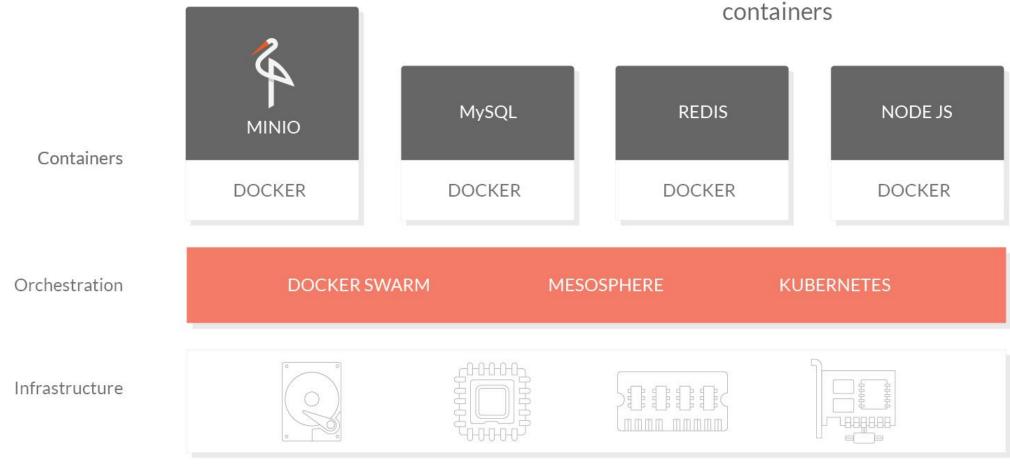


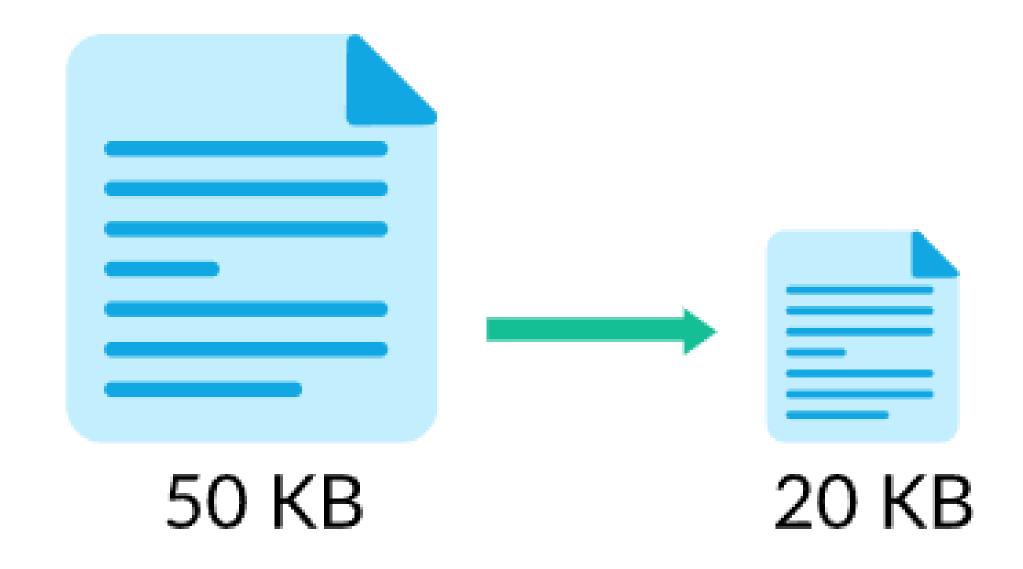
```
λ mc support perf minio-aws
(With 64 MiB object size, 32 concurrency) PUT: 156 GiB/s GET: 304 GiB/s
(With 64 MiB object size, 48 concurrency) PUT: 166 GiB/s GET: 318 GiB/s
(With 64 MiB object size, 72 concurrency) PUT: 167 GiB/s GET: 325 GiB/s
MinIO 2022-01-08T03:11:54Z 32 servers, 256 drives
PUT: 167 GiB/s, 2,670 objs/s
GET: 325 GiB/s, 5,197 objs/s
λ
```



minio server http://host{1...n}/export{1...m}

Provision object storage as containers





Compression Guide Slack channel 18817

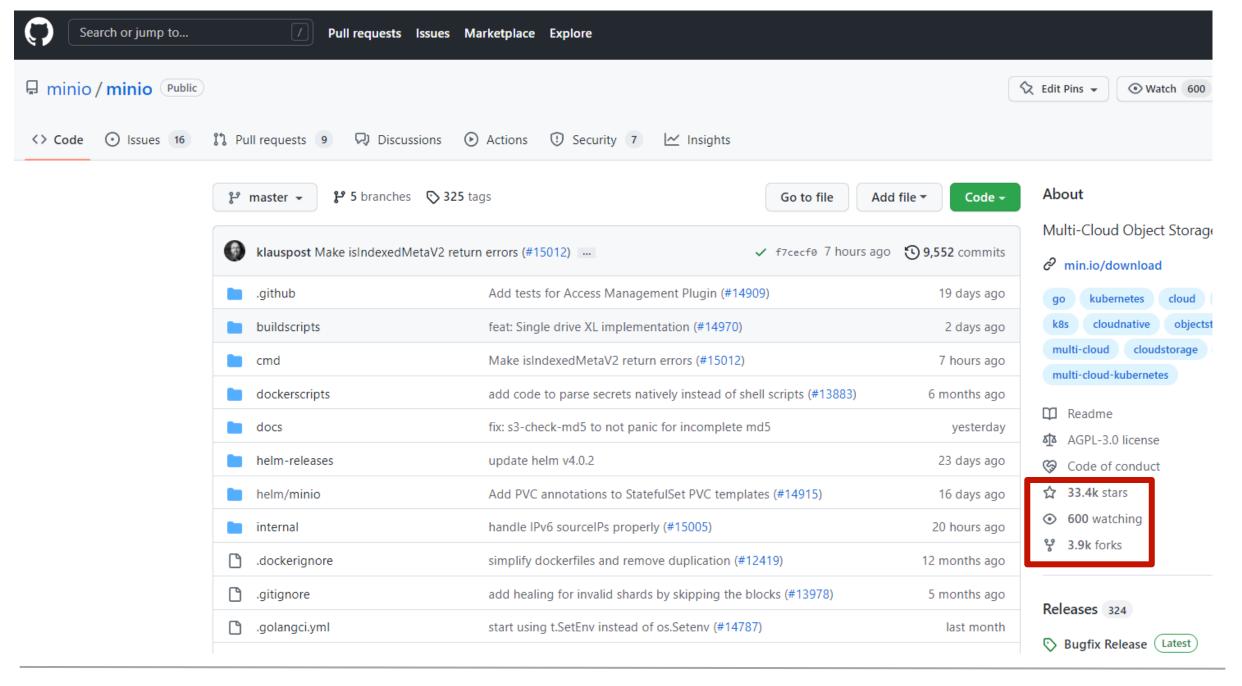
MinIO server allows streaming compression to ensure efficient disk space usage.

Compression happens inflight, i.e objects are compressed before being written to disk(s).

MinIO use klauspost/compress/s2

streaming compression due to its stability and performance.

This algorithm is specifically optimized for machine generated content. Write throughput is typically at least 500MB/s per CPU core, and scales with the number of available CPU cores. Decompression speed is typically at least 1GB/s.



Проблемы при внедрении

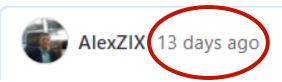


MinIO fault tolerance with big drives and nodes counts #15026



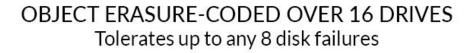
Answered by klauspost

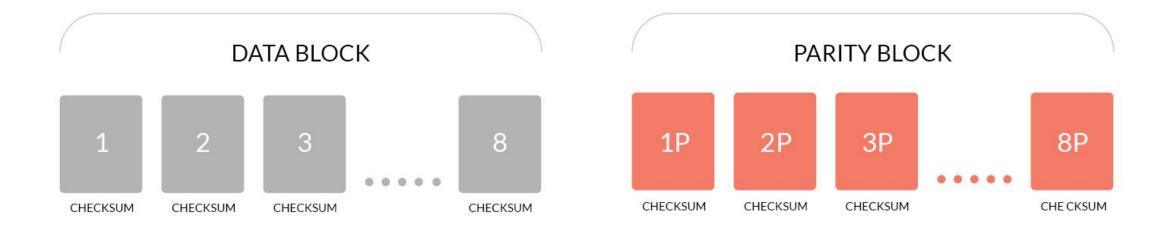
AlexZIX asked this question in Q&A



* * *

Erasure code (EC)





Erasure Set Size	Defaut групда дисков размером вт Идо 16 М – всего дисков на всех нодах
5 or fewer	N – диски с информацией для восстановления
6-7	 N <= TRUNC(M / 2) N <= 8 Потеря N/2 дисков = readonly
8 or more	• Потеря N/2-1 дисков = readwrite EC:4

For example, an 16-server distributed setup with 200 disks per node would continue serving files, up to 4 servers can be offline in default configuration i.e. around 800 disks down MinIO would continue to read and write objects.

- N <= TRUNC(M / 2)
- N <= 8

http://minio-{1...16}.example.net/disk{1...200}



http://minio-{1...16}.example.net/disk{1...200}

http://minio-{1...16}/disk1 http://minio-{1...16}/disk2 ... http://minio-{1...16}/disk200

Наигрались – давайте денег



harshavardhana 13 days ago

Maintainer

@AlexZIX these discussions are best had on a call with our sales involved feel free to reach out to us at sales@min.io

We can recommend hardware and size your cluster appropriately.



ravindk89 13 days ago

Collaborator



@AlexZIX MinIO automatically handles generating erasure code sets - and in fact your first syntax would create multiple single-disk pools, which would be very inadvisable.

We have general documentation on running MinIO in distributed mode here. As noted, more specific sizing and hardware recommendations are handled through professional engagement.

Total Drives (N)	Data Drives (D)	Parity Drives (P)	Storage Usage Ratio
16	8	8	2.00
16	9	7	1.79
16	10	6	1.60
16	11	5	1.45
16	12	4	1.34
16	13	3	1.23
16	14	2	1.14

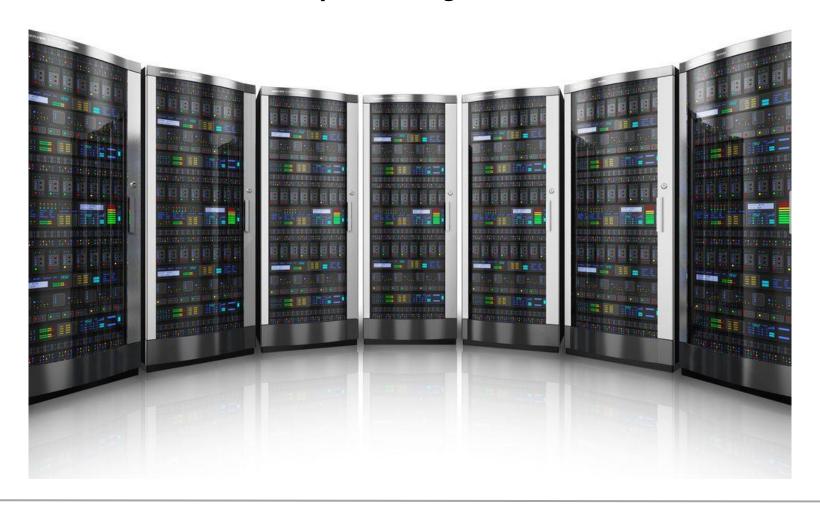
Классы хранения

```
export MINIO_STORAGE_CLASS_STANDARD=EC:3
export MINIO_STORAGE_CLASS_RRS=EC:2
```

EECMC²

Тестовый стенд

«For example, an 16-server distributed setup with 200 disks per node...» (https://docs.min.io/docs/distributed-minio-quickstart-guide.html)



Выбор оборудования

MINIO MINIMUM REQUIREMENTS



Processor

Dual Intel® Xeon® Scalable Gold CPUs (minimum 8 cores per socket).



Drives

SATA/SAS HDDs for capacity and NVMe SSDs for high-performance (minimum of 8 drives per server).



Network

25GbE for capacity and 100GbE NICs for highperformance.



Memory

128GB RAM

Выбор оборудования

СРU: 8 ядер Intel Xeon E5-2650 v4

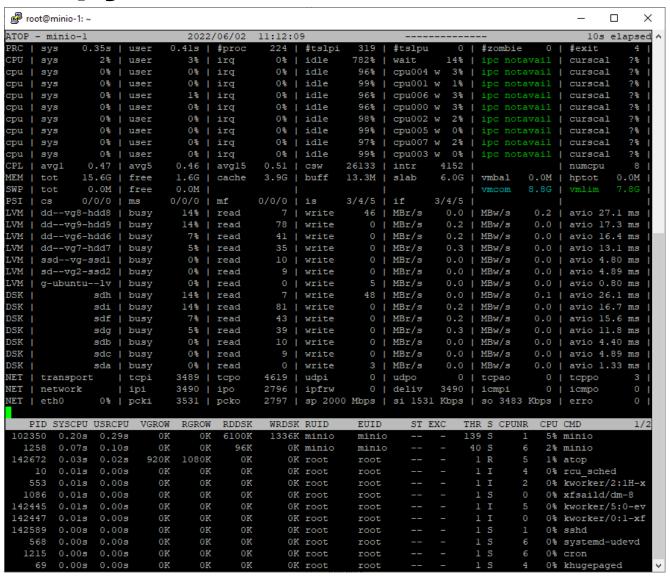
RAM: 16G

SSD: NVME Intel P4608i 6.4 TB

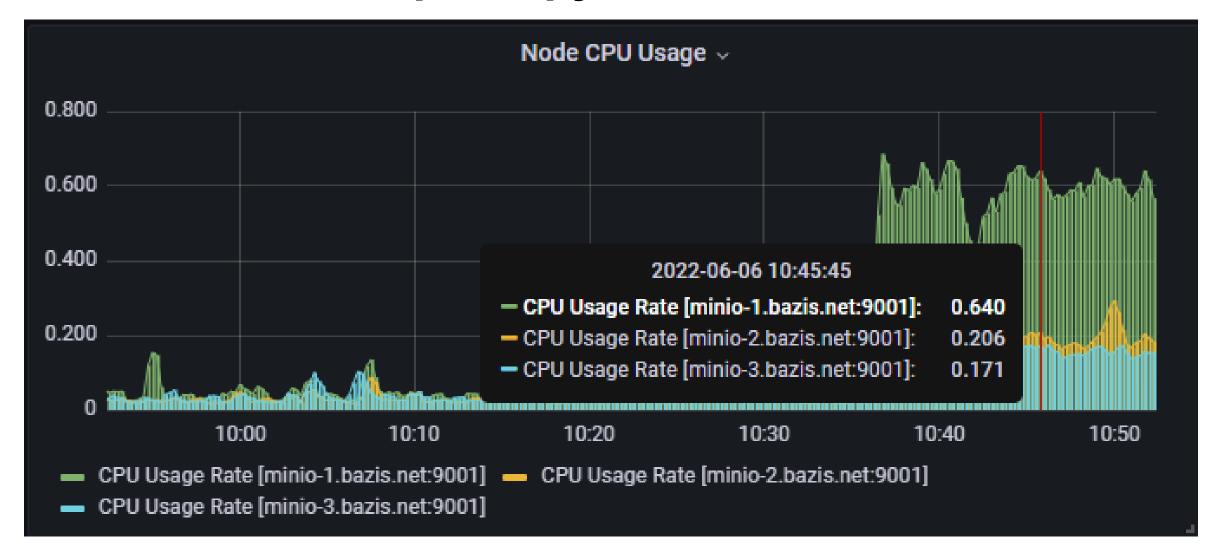
HDD: SATA Seagate Barracuda

ST5000LM003 5 TB

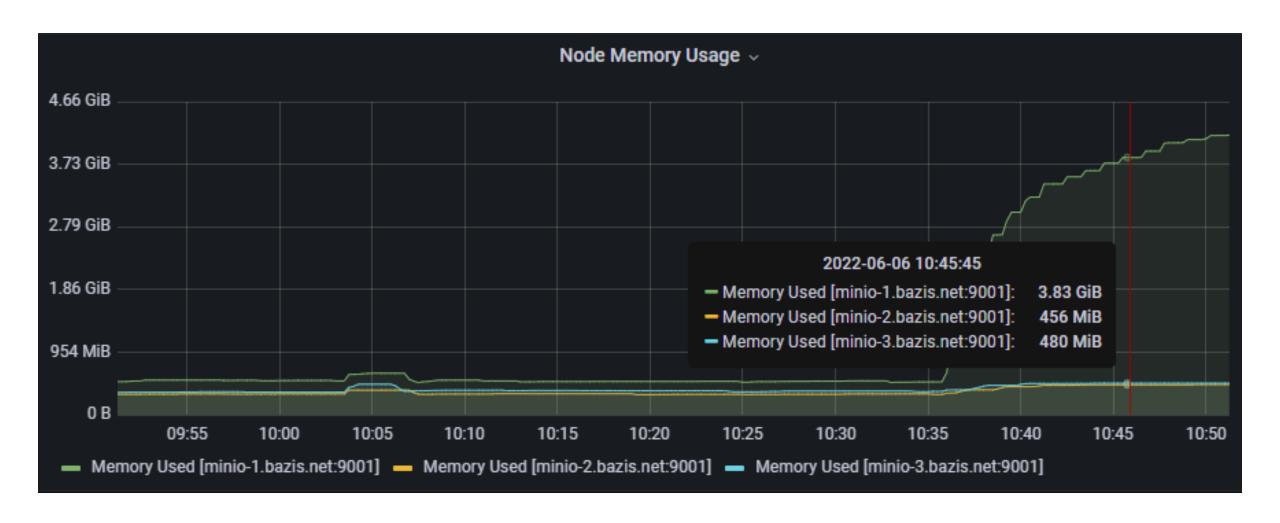
NODES: 3



Выбор оборудования - CPU



Выбор оборудования - RAM



Масштабирование

http://minio-{1...16}.example.net/disk{1...200}

http://minio-{1...16}/disk{1...200} http://minio-{17...32} /disk{1...200}

MinIO generally recommends planning capacity such that server pool expansion is only required after **2+ years** of deployment uptime.

Do **not** perform "rolling" (e.g. one node at a time) restarts.

Выбор архитектуры

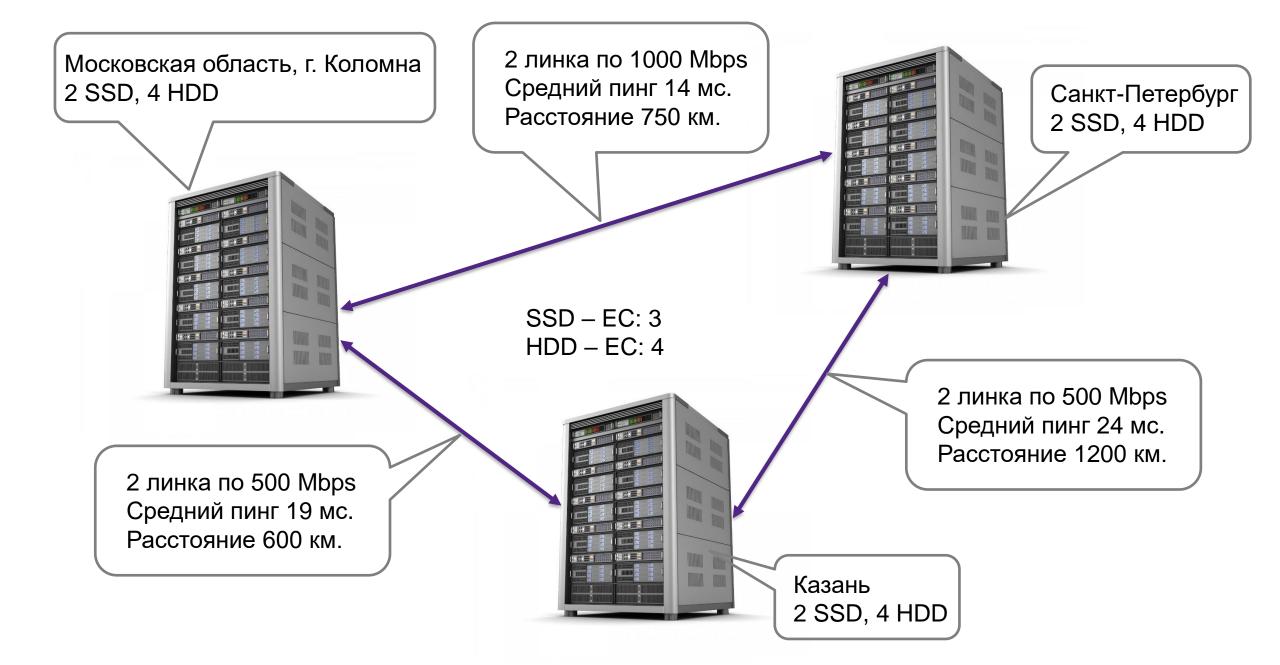
РАСПРЕДЕЛЁННАЯ

- Больше объём хранения с тем же количеством дисков
- Не нужно включать версионирование
- Можно развернуть узлы в большем количестве локаций
- Объект гарантированно доступен на всех узлах сразу после загрузки
- Пользователи и политики применены сразу ко всему кластеру

РЕПЛИКАЦИЯ

- Выше скорость если каждый из кластеров размещён в своём ДЦ
- Лучше изолированность и отказоустойчивость

Проблемы при эксплуатации

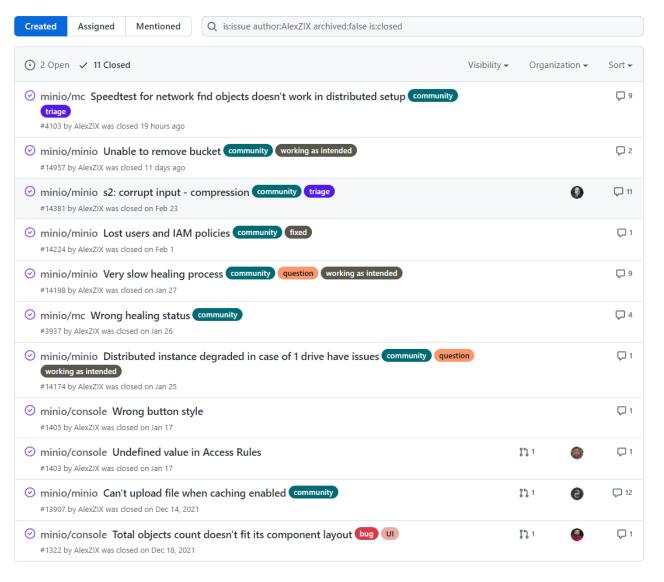


Критические ошибки

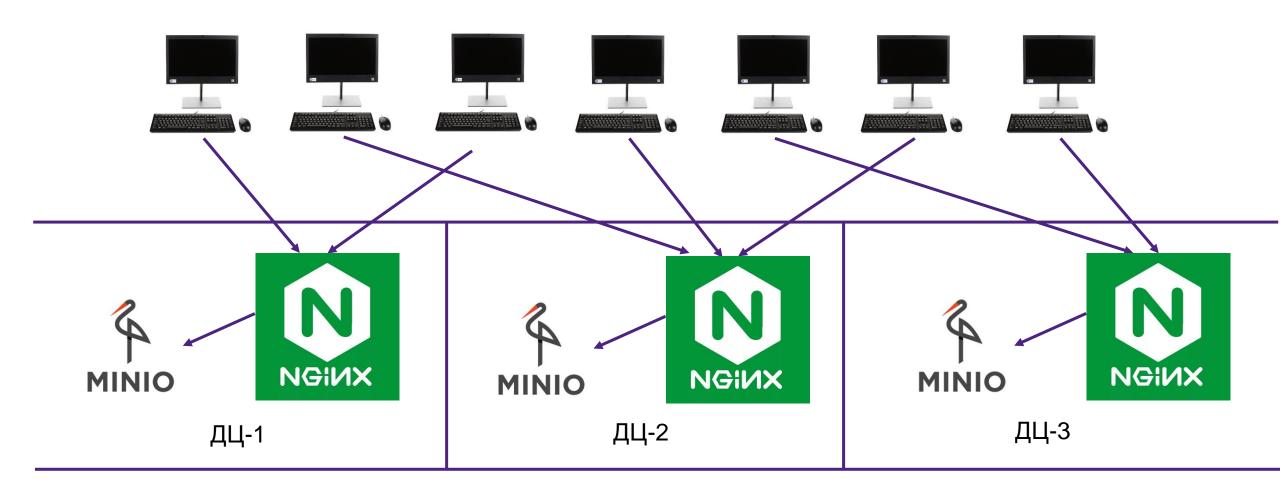
#14224 - пропали все пользователи и политики

#13907 - неверно работало кэширование

#14381 - побились сжатые файлы



CDN на базе MinIO + NGINX

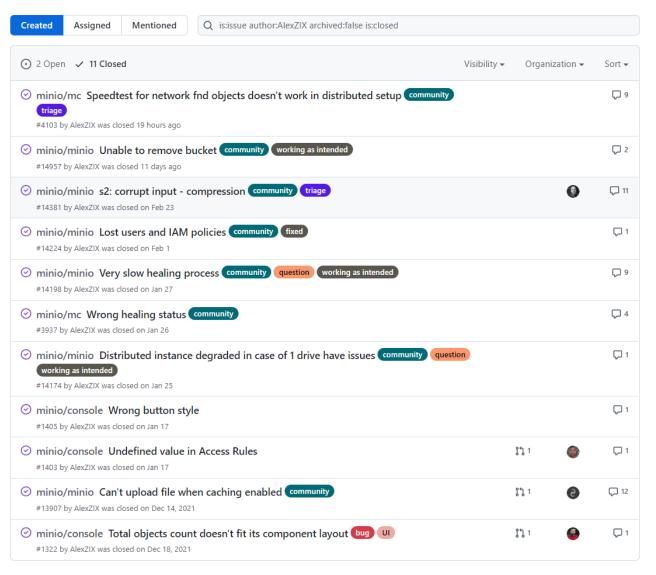


Критические ошибки

#14224 - пропали все пользователи и политики

#13907 - неверно работало кэширование

#14381 - побились сжатые файлы



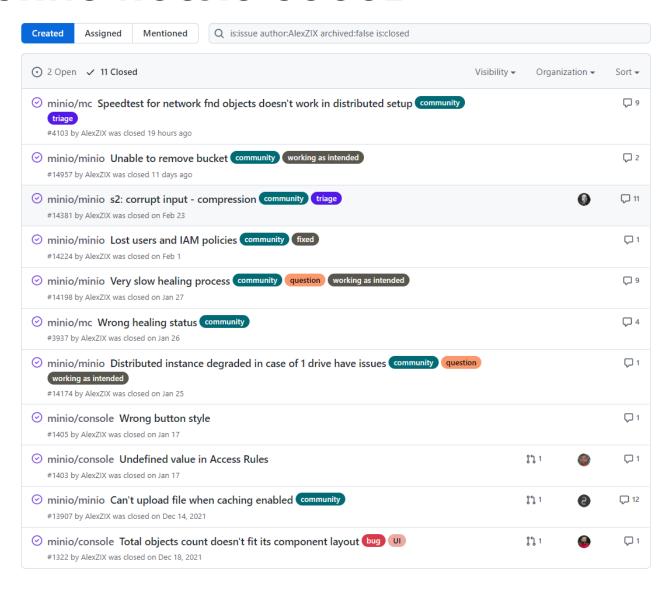
Восстановление после сбоев

#3937 - неверное отображение хода восстановления

#14198 - восстановление занимает оооочень долгое время

#14174 - деградация кластера в случае выхода из строя одного из дисков

Невозможность доступа к консоли управления в случае выхода из строя N дисков.

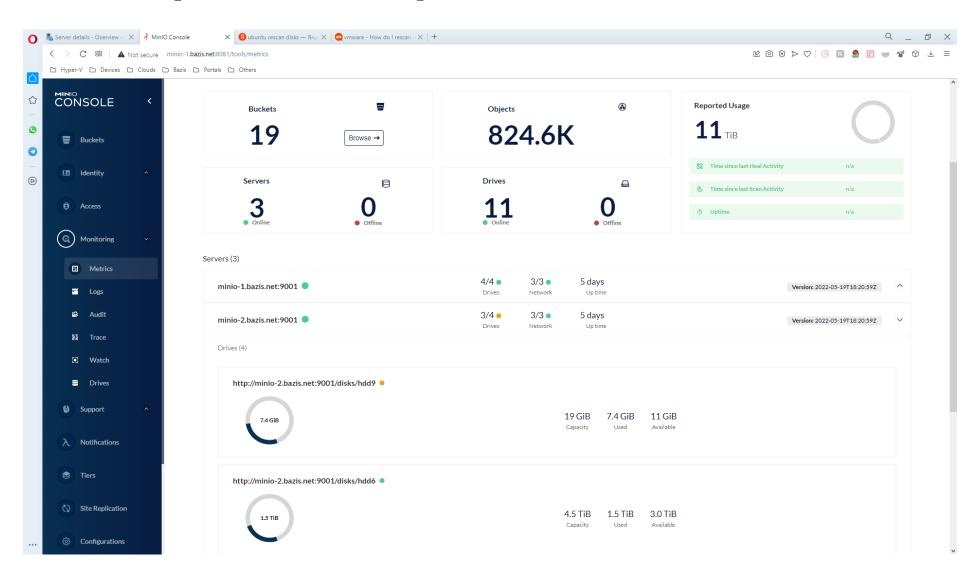


Реальный срок восстановления непрогнозируем

```
root@minio-1:~# mc admin heal minio-cold
Objects Healed: 445,542/893,160 (49.8%%), 6.4 TB/13 TB (50.7%%)
Heal rate: 0 obj/s, 258 B/s
Estimated Completion: 1 month

root@minio-1:~#
```

Деградация производительности



Отсутствие мониторинга дисков





klauspost commented on Jan 25

Contributor

or

Unmount a partially failed drive:

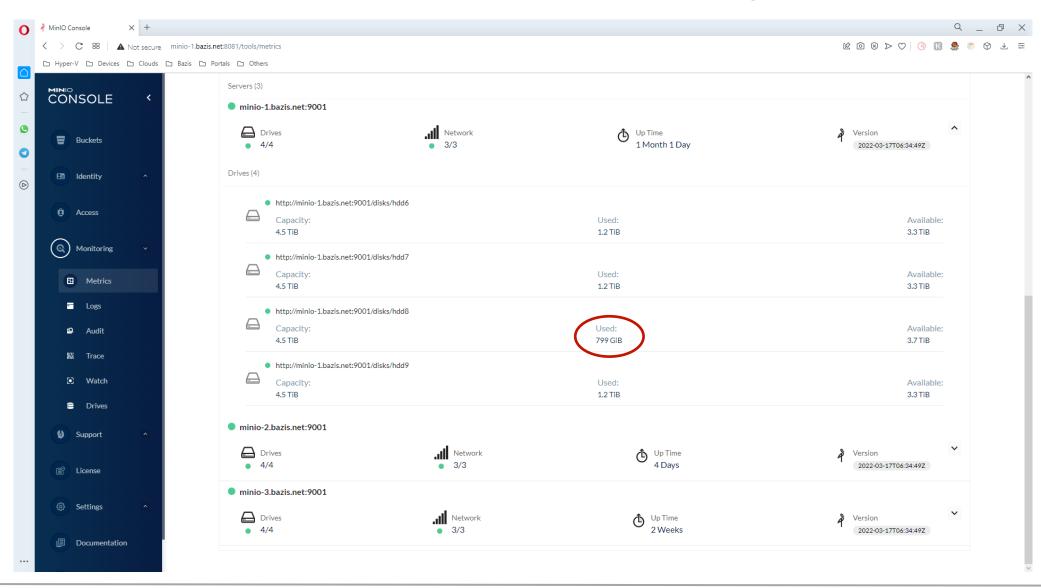
For nodes with one or more drives that are either partially failed or operating in a degraded state (increasing disk errors, SMART warnings, timeouts in MinIO logs, etc.), you can safely unmount the drive if the cluster has sufficient remaining healthy drives to maintain read and write quorum. Missing drives are less disruptive to the deployment than drives that are reliably producing read and write errors.

https://docs.min.io/minio/baremetal/installation/restore-minio.html

MinIO поверх ZFS

root@minio-2:~# zpool list										
NAME	SIZE	ALLOC	FREE	CKPOINT	EXPANDSZ	FRAG	CAP	DEDUP	HEALTH	ALTROOT
hdd6	4.55T	1.28T	3.26T	_	_	5%	28%	1.00x	ONLINE	_
hdd7	4.55T	1.28T	3.26T	_	_	5%	28%	1.00x	ONLINE	_
hdd8	4.48T	1.28T	3.20T	_	_	5%	28%	1.00x	ONLINE	_

Нет точных данных об используемом месте



И что в итоге





Вопросы

Алексей Плетнёв Базис-Центр zix@bazissoft.ru